



# SISTEMA DE IDENTIFICAÇÃO DE AERONAVES MILITARES

**Grupo:**

- Bruno Henrique
- Christian David
- Daniel Lucas
- Gabriel Luna
- Lucas Z. Duarte

- 03 INTRODUÇÃO
  - 04 REVISÃO LITERÁRIA
  - 05 VISAO GERAL DO SISTEMA
  - 06 CNN
  - 07 MODULOS DO SISTEMA
  - 10 RESULTADOS
  - 14 CONCLUSÃO
- 



# INTRODUÇÃO



- Sistema capaz de identificar aeronaves com possíveis ameaças.
- Sistema detectará e retornará dados dos aviões detectados.
- Informação para construção de estratégias de segurança.



# REVISÃO LITERÁRIA

---

FLIGHT SCOPE:  
A DEEP COMPREHENSIVE ASSESSMENT OF  
AIRCRAFT DETECTION ALGORITHMS IN  
SATELLITE IMAGERY

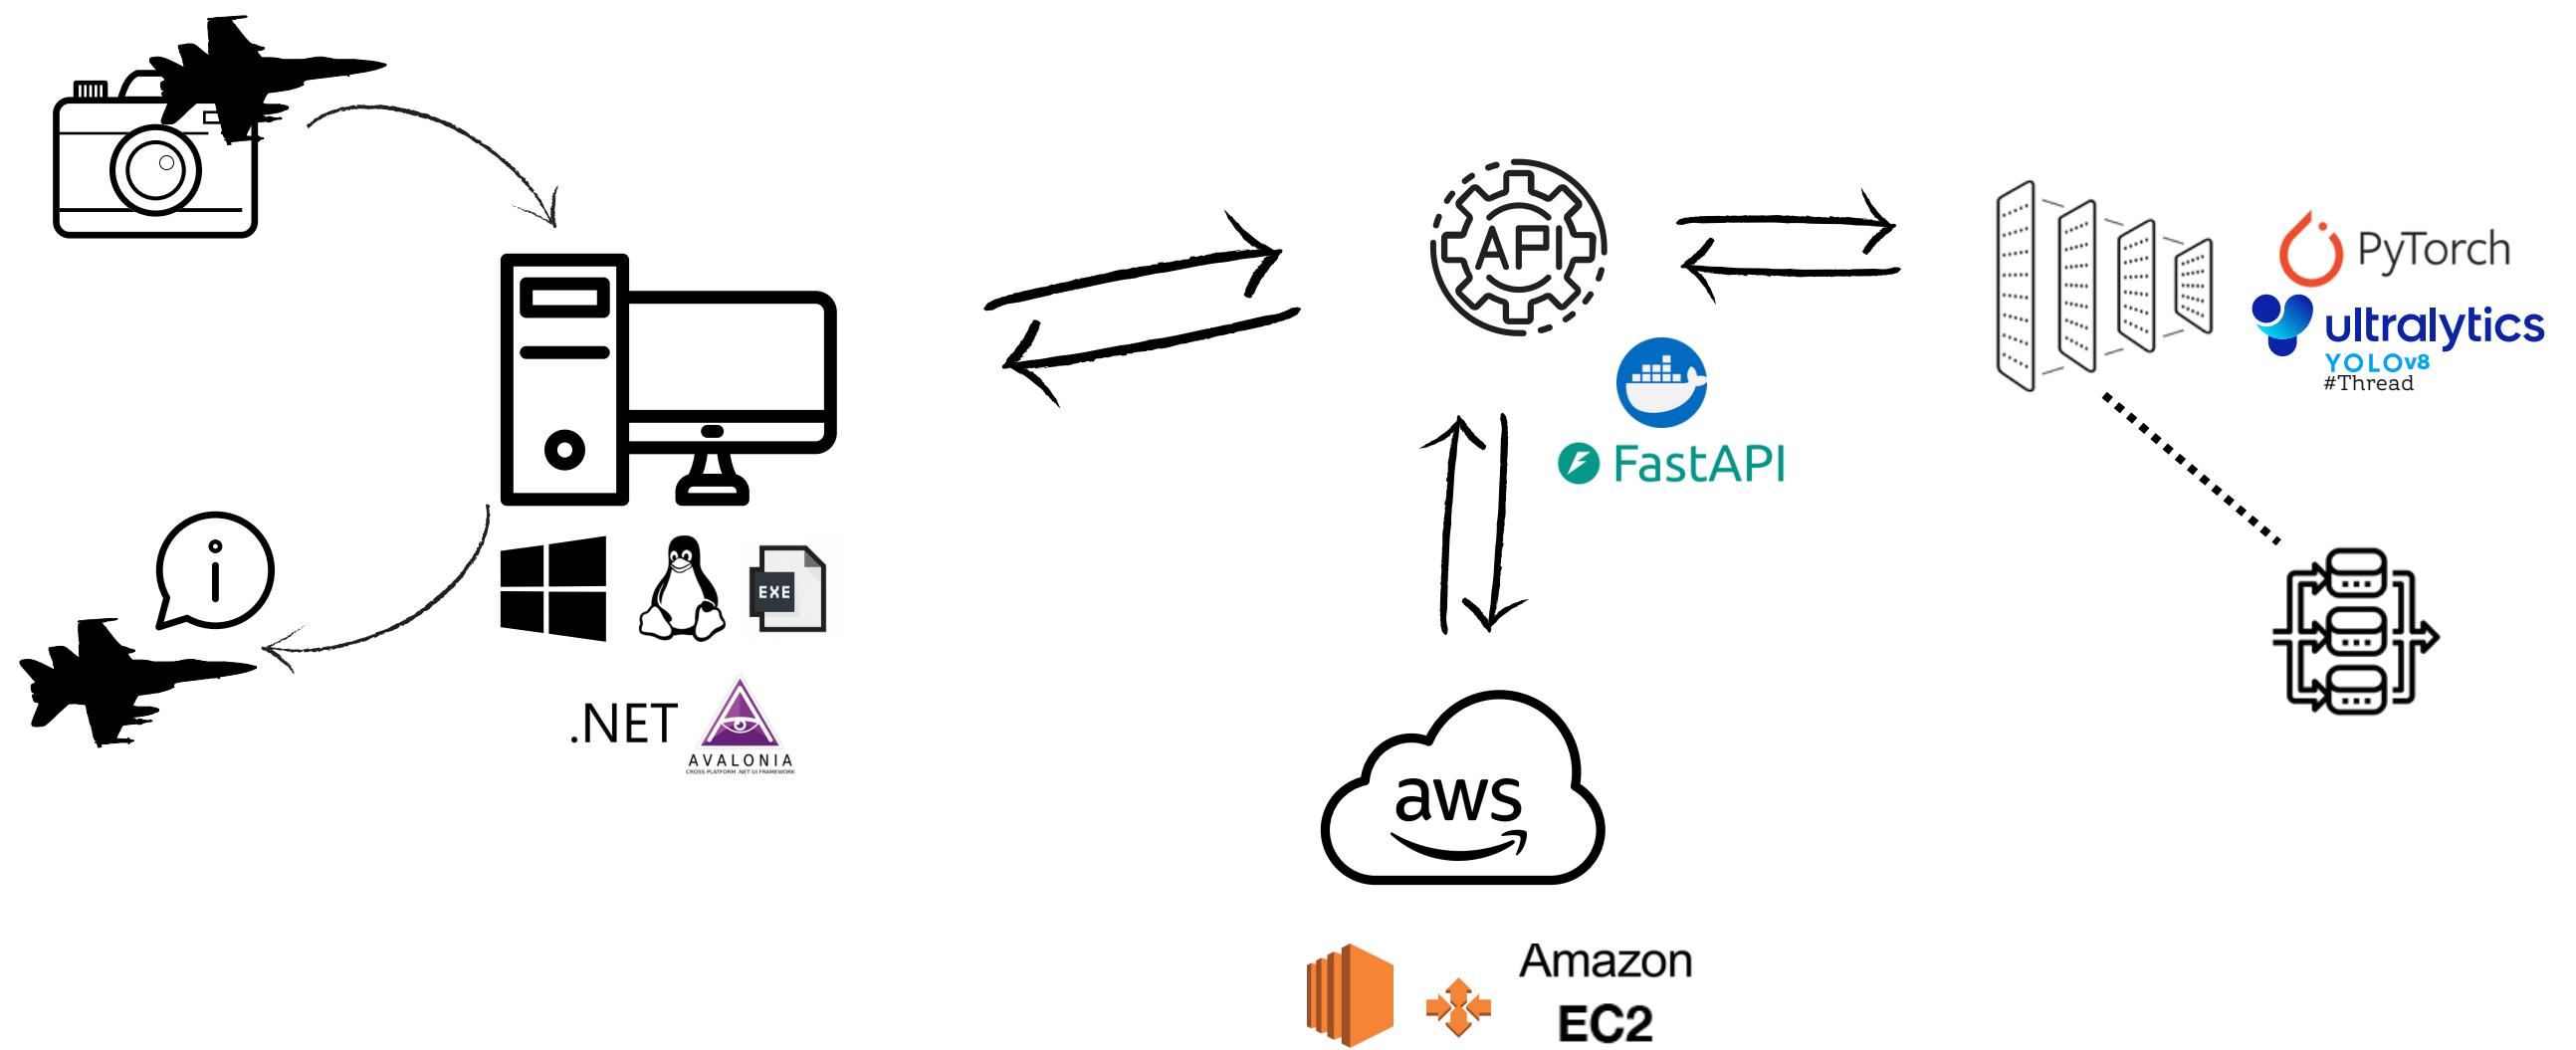
TRANSEFFIDET:  
AIRCRAFT DETECTION AND  
CLASSIFICATION IN AERIAL IMAGES BASED  
ON EFFICIENTDET AND TRANSFORMER



---

# TOPOLOGIA

MAPA DE IMPLEMENTAÇÃO

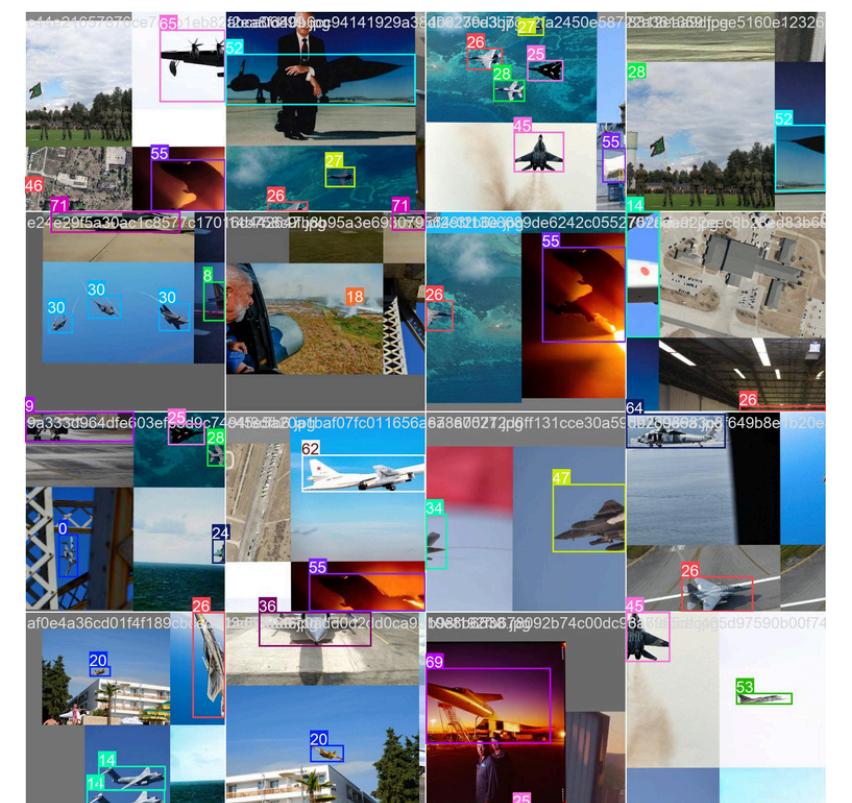
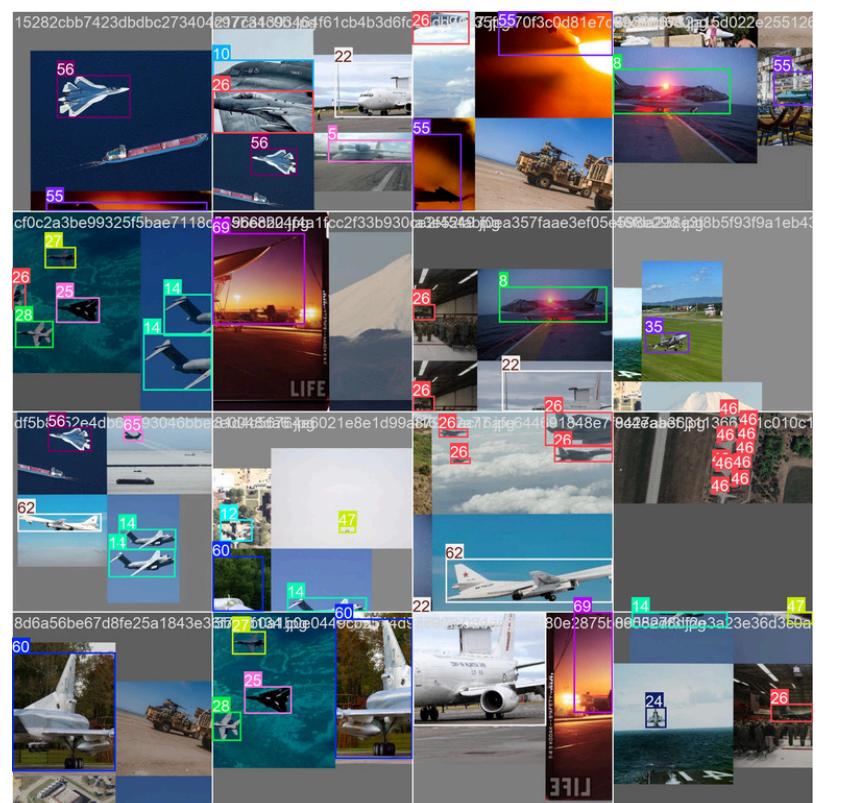
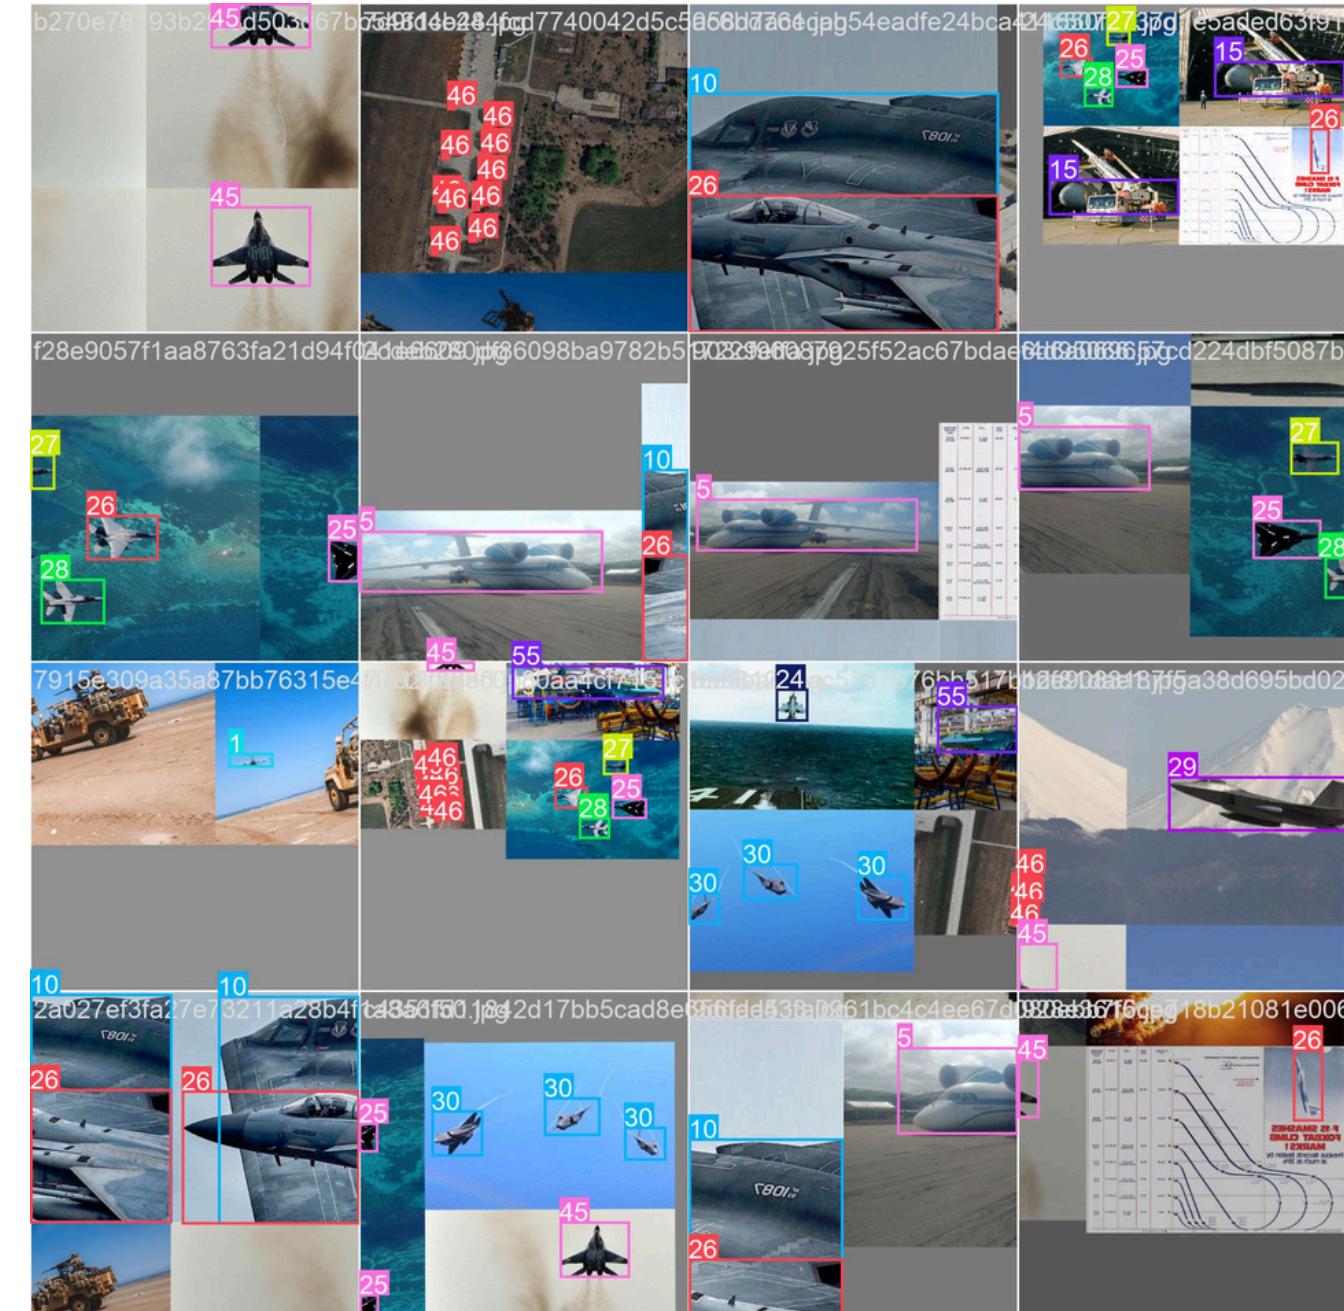




## METODOLOGIA DE DESENVOLVIMENTO

# CNN PYTORCH - YOLO

- Conversão da base de dados para formato YOLO
- Treinamento/validação do YOLOV8
- Perdas e métricas de desempenho
- Modelo YOLOv8 foi preciso e uma boa solução



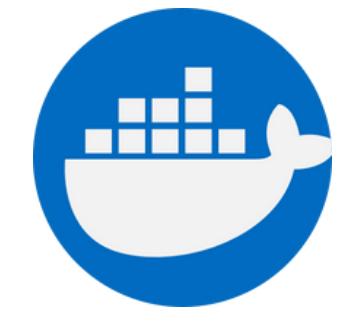


METODOLOGIA DE DESENVOLVIMENTO

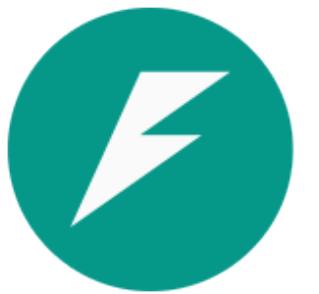
---

# SISTEMAS

- API



docker



FastAPI



```
{  
    "predictions": [  
        {  
            "xmin": 264.39996337890625,  
            "ymin": 248.94970703125,  
            "xmax": 2248.373046875,  
            "ymax": 1194.711669921875,  
            "confidence": 0.484796941280365,  
            "class": 0,  
            "label": "A10",  
            "segmentation": null  
        },  
        {  
            "xmin": 265.84185791015625,  
            "ymin": 253.197509765625,  
            "xmax": 2252.1884765625,  
            "ymax": 1188.281982421875,  
            "confidence": 0.3605268597602844,  
            "class": 51,  
            "label": "RQ4",  
            "segmentation": null  
        }  
    ]  
}
```





---

# SISTEMAS DISTRIBUIDOS



Amazon  
**EC2**

- Utilização do Amazon EC2 para o modelo do YOLOv8:
  - Predições em tempo real.
- A integração com FastAPI:
  - Comunicação eficiente entre cliente e modelo
- Vantagens:
  - Robustez da AWS.
  - Balanceamento de carga nativo.
  - Instâncias otimizadas para CUDA.



Artigo de Apoio:



Cuconv: A Cuda Implementation Of Convolution For Cnn Inference

- CUDA otimizou o modelo YOLOv8:
  - Execução em GPUs:
    - Redução drástica no tempo de processamento.
  - Paralelismo com Multi-GPU:
    - Cada GPU uma parte
- Especificações da máquina do treino:
  - Windows 11
  - 16GB de RAM DDR4 3200MHz
  - Intel Core i5 11400H 2.7GHz
  - Nvidia RTX 3050M 4GB GDDR6



- **Tempo de 10 epochs:**
  - Sem paralelismo (CPU): 1h:32m por epoch | Total: 15h:19m:59s
  - Com paralelismo (GPU): 4m:30s por epoch | Total: 45m
- **SpeedUp:** 20,44 vezes mais rápido
- **Eficiência:** 20,44, pois 1 processador foi utilizado
- **Testes de Escalabilidade:** 95,11% de redução no tempo de execução
- **Escalabilidade Fraca:** 90,25% de eficiência para o dobro de número de epochs
- **Tempo para previsão:** 100ms

# DEMO

Home

History

Upload



Ultimas predições:

F16  
97.99%

F16  
97.99%

F35  
96.50%

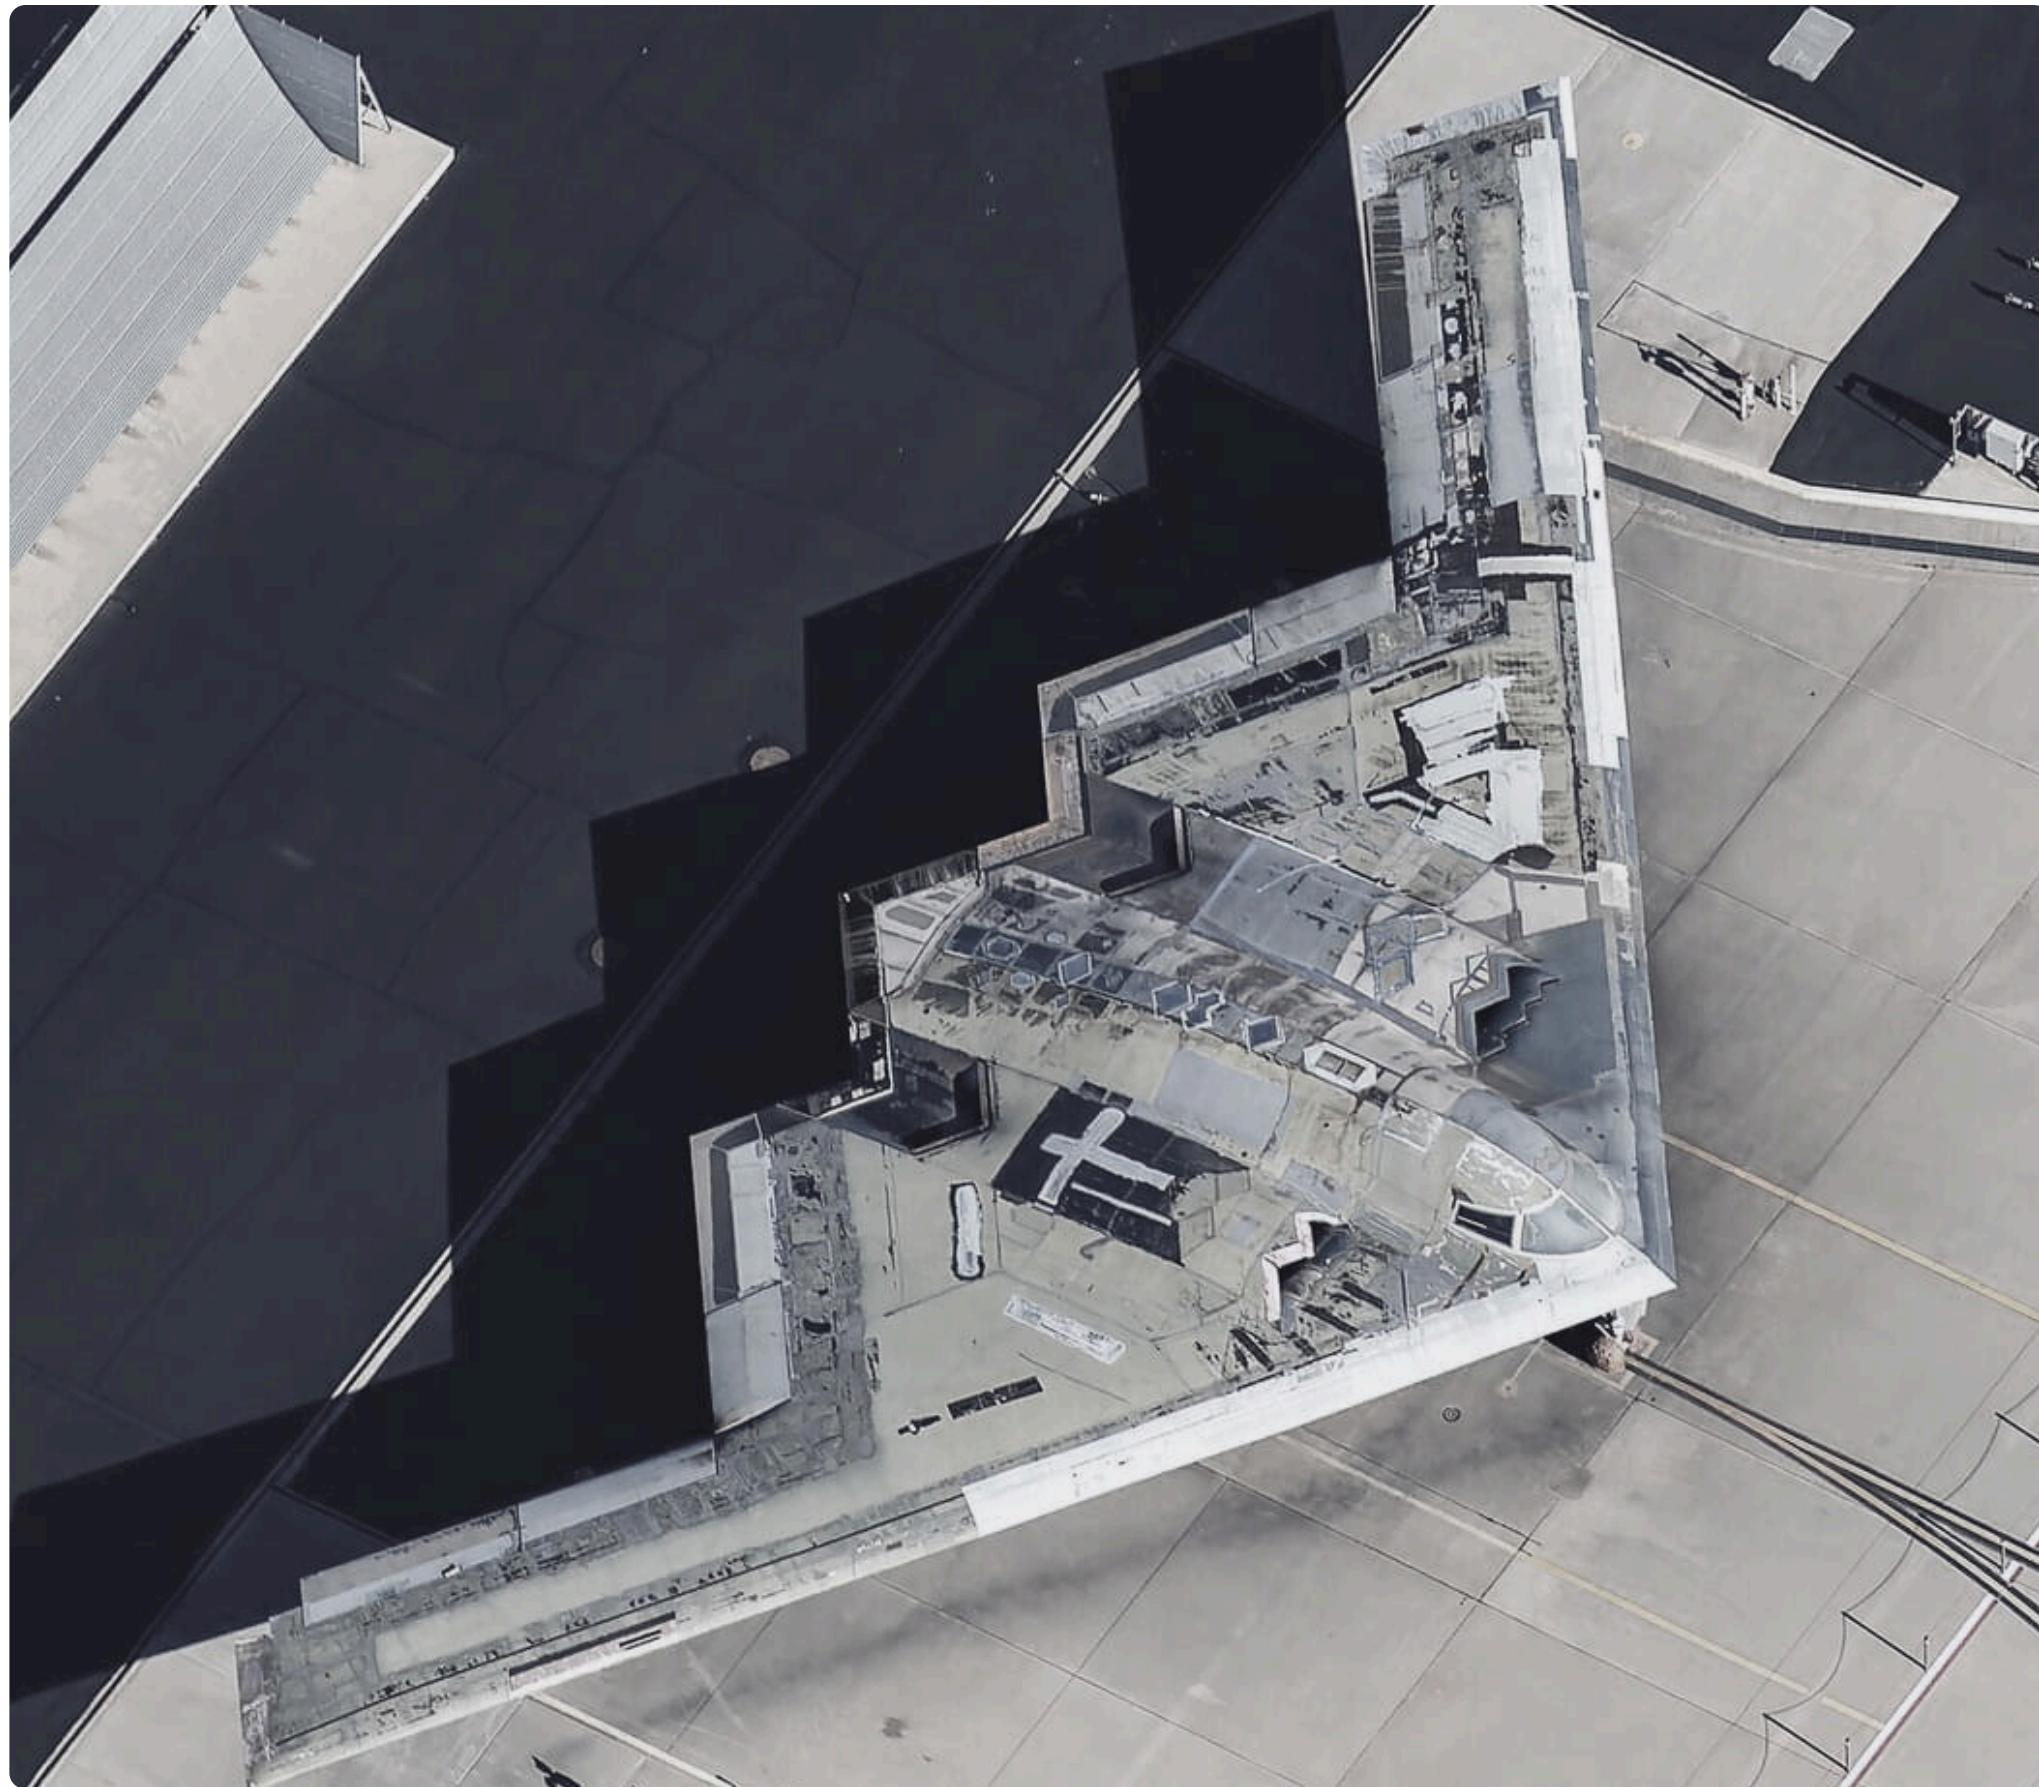
C5  
95.70%

● Servidor Online

# CONCLUSÃO

- Benefícios da Computação Paralela e Distribuída:
  - Aceleração do Processamento;
  - Eficiência de Recursos;
  - Escalabilidade;
  - Maior Desempenho e Flexibilidade





OBRIGADO!